

从“模型优先”到“世界模型优先”：面向 AI 市场分析的

加密货币数据世界模型基础设施研究

李国聪¹

(投稿版模板, 日期: 2026 年 5 月 18 日)

英文题名: From “Model-First” to “World-Model-First”: A Study of Cryptocurrency Data World Model Infrastructure for AI-Based Market Analysis

基金项目: 此处填写基金项目名称与编号 (如无, 可在正式投稿前删除)。

作者简介: 李国聪, 研究方向为 AI 市场分析、量化数据基础设施与金融统计建模。

中图分类号: F830.9; TP18 **文献标识码:** A **文章编号:** 待定

摘要: 本文研究一个在 AI 金融应用讨论中经常被忽视、但对真实落地至关重要的问题: 对于需要持续理解市场状态、形成条件判断并输出可审计结论的智能系统而言, 其能力上限往往并不首先受模型复杂度约束, 而首先受制于其所面对的市场世界是否足够宽、足够稳、足够诚实。围绕项目文档中提出的“多数 AI 交易系统失败, 并非因为模型不够聪明, 而是因为喂给模型的市场世界观过于单薄”这一核心命题, 本文不将当前项目视为收益预测器或自动交易引擎, 而将其界定为一种面向 AI 市场分析的数据世界模型基础设施。本文结合项目文档、代码结构、数据库语义与逻辑层 bundle 机制, 构建了一个从潜在市场状态到 AI 可见世界对象的理论框架; 进一步从宽度、稳定性与诚实性三个维度定义世界模型质量, 并引入世界模型质量指数、解释波动率、无支撑断言率、陈旧输入敏感度与证据归因率等评价对象。研究表明, 当前项目的核心价值不在于直接给出交易答案, 而在于通过 `latest_*` 快照、质量门控、主视图与诊断视图分离、八证据带 bundle 聚合和时间治理, 降低世界模型误差、压缩解释空间的伪自由度, 并提高 AI 结论的可审计性与制度可用性。本文的边际贡献在于把“市场世界模型”从工程叙事提升为可形式化、可识别、可评估的学术对象。

关键词: AI 市场世界模型; 加密货币; 数据基础设施; 市场微观结构; 信息集; 质量治理

Abstract: This paper studies an overlooked but fundamental issue in AI-based financial applications: for an intelligent system that continuously interprets market states and produces auditable judgments, its performance frontier is often constrained less by

¹作者姓名拼音: Li Guocong。作者邮箱: lmul51638@gmail.com。本文研究对象是当前项目所构建的数据层与逻辑聚合层系统, 不将其误写为已经闭环完成的自动交易代理。

model complexity than by whether the market world presented to it is sufficiently broad, stable, and honest. Motivated by the proposition that many so-called AI trading systems fail not because the model is not smart enough, but because the market worldview fed into the model is too thin, this paper does not treat the current project as a return predictor or an automated trading engine. Instead, it conceptualizes the project as a data world model infrastructure for AI-based market analysis. Combining project documentation, code structure, database semantics, and logic-layer bundle construction, the paper develops a formal framework that maps latent market states to AI-visible world objects. It then defines world model quality along three dimensions—breadth, stability, and honesty—and proposes evaluative objects such as the World Model Index, explanation volatility, unsupported claim rate, stale-input sensitivity, and evidence attribution rate. The analysis suggests that the core value of the project lies not in directly generating trading answers, but in reducing world-model error, compressing spurious explanatory degrees of freedom, and improving the auditability and institutional usability of AI conclusions through `latest_*` snapshots, quality gating, the separation of main and diagnostic views, bundle aggregation across eight evidence bands, and temporal governance. The paper contributes by elevating the notion of a “market world model” from an engineering narrative to a formal, identifiable, and evaluable academic object.

Key words: AI market world model; cryptocurrency; data infrastructure; market microstructure; information set; quality governance

JEL 分类号: G10, G17, C55, C82, O33

1 引言

1.1 研究背景

在公开叙事中，AI 交易系统的失败往往被归因于模型不够先进、参数调优不足或提示词设计不够精细。然而，这类解释在真实市场环境中经常抓错主要矛盾。对于一个承担市场分析任务的智能系统而言，真正决定其分析边界的，不只是模型函数逼近能力，更是其所面对的市场世界是否足够完整、足够及时、足够可信。

这一问题在加密货币市场中尤为突出。加密市场并非由单一路径价格序列充分刻画。相同的价格走势，在不同交易所结构、不同杠杆拥挤状态、不同资金费率环境、不同期权墙位分布、不同解锁周期和不同宏观背景之下，往往对应完全不同的市场含义。因此，若 AI 仅观察 K 线，它看到的只是价格轨迹而非市场结构；若其仅读取新闻标题，它接触到的则是叙事噪声而非执行约束；若其仅面对一张历史大表，它也未必真

正得到“此刻市场是什么样”的在线世界对象。

本文据此提出一个更底层的问题：**如何为 AI 构建一个足够宽、足够稳、足够诚实的市场世界模型，使其输入空间更接近真实市场的多层结构？**

1.2 研究对象与论文定位

本文所研究的“当前项目”²并不是一个单纯的数据抓取脚本集合，也不是一个已经闭环完成的自动交易系统。基于项目文档与代码结构，本文更准确地将其定位为一个面向 AI 的加密市场数据基础设施项目。其目标不是直接替 AI 下单，而是：

1. 从外部真实世界持续采集市场、宏观、链上、新闻、期权、供给与替代数据；
2. 对异构数据进行标准化、落库、快照同步和质量治理；
3. 在逻辑层将分散观测重组为 AI 可以直接消费的结构化市场上下文。

基于这一定位，本文研究的不是“该代码库能否直接产生超额收益”，而是如下四个问题：

1. 当前项目如何把真实市场映射为一个适合 AI 消费的数据世界模型？
2. 相较于薄信息、单来源、单频率输入，这种世界模型理论上为 AI 带来哪些信息论与决策论优势？
3. 项目中的分层架构、latest_* 快照、质量门控、主视图与诊断视图分离等设计分别解决了哪些方法论问题？
4. 这一项目在 AI 市场分析系统中所扮演的角色，应如何被学术化地理解、度量与评估？

1.3 研究贡献

本文的研究贡献可概括为四点。第一，本文把 AI 交易系统的失败原因从通常被讨论的模型层前移到观测层和数据治理层，强调世界模型构造错误本身就是一类一等错误。第二，本文将“足够宽、足够稳、足够诚实的数据世界模型”形式化为可研究对象。第三，本文将当前项目的模块化采集、数据库快照、质量门控、bundle 聚合与调度矩阵系统映射到“世界模型生成器”的理论框架。第四，本文提出一套未来可执行的研究议程，用于比较薄世界模型与厚世界模型在 AI 市场分析任务中的差异。

²本文所称“当前项目”，是指仓库及其配套文档所描述的数据层与逻辑聚合层系统，不包括尚未在仓库中实现的交易执行代理。

1.4 文章结构

全文安排如下：第二部分回顾相关文献并说明本文的理论位置；第三部分建立世界模型优先的形式化框架；第四部分将项目架构与数据库契约映射为世界模型生成系统；第五部分分析项目对 AI 市场分析的具体作用；第六部分提出可发表级的识别与评估框架；第七部分将本文与经典资产定价、机器学习、测量误差和 data-centric AI 文献对话；第八部分讨论局限性与外部有效性；第九部分给出结论。

2 文献综述与理论定位

2.1 资产定价文献中的条件信息集问题

经典资产定价文献通常在某一条件信息集上讨论预期收益、风险补偿与贴现率变化。例如 Fama and French 的因子定价框架强调少量稳定因子的横截面解释能力，而 Cochrane 的随机贴现因子框架强调条件信息集对贴现环境识别的重要性 [4, 5, 6, 3]。这些研究共同依赖一个隐含前提：研究者已经拥有一个相对稳定、结构清晰的信息世界。

然而，在加密市场中，这一前提更容易失真。交易所分裂、执行摩擦、资金费率、basis、爆仓、期权拥挤、链上资本迁移与代币供给冲击，使得单一价格序列难以充分代表真实市场状态。若继续沿用狭义价格因子或低频特征近似该状态，则等于用一个过薄的信息集去逼近高维动态世界。

2.2 机器学习金融文献中的高维特征扩张

机器学习资产定价文献表明，更丰富的特征输入与非线性映射可在严格样本外设计下提高统计预测能力 [12, 8, 15]。但 Harvey, Liu and Zhu [10] 也提醒，高维扩张会显著加剧数据挖掘偏误、多重检验问题与伪显著性风险。因此，特征多样性只有在来源质量、语义契约与治理机制足够清晰时才真正有意义。

本文与该文献的区别在于：本文不首先把“更多特征”理解为模型优势，而是把“特征系统如何被治理、如何被时间对齐、如何被质量门控”理解为研究对象本身。换言之，本文关注的不仅是高维输入，而是高维输入背后的世界模型组织原则。

2.3 市场微观结构、测量误差与鲁棒决策

Makarov and Schoar [14] 强调了加密市场中跨交易所套利摩擦的重要性；Liu, Tsyvinski and Wu [13] 则表明加密资产存在可识别的共同风险因子。更广义地，测量误差文献指出，当观测值带有系统性噪声、延迟或错配时，估计与预测结果都会发生偏移 [7, 2]。鲁棒控制文献进一步强调，在面对不确定环境时，理性决策者应先识别

自己所依赖的信息世界是否可靠 [9]。

当前项目可以被理解为对这些问题的一种工程化回应。它不是直接估计经典的 errors-in-variables 模型，而是在数据层显式管理观测延迟、质量降级、来源缺口和语义错位，从而为 AI 构造一个更可靠的信息表面。

2.4 与 data-centric AI 的关系

若将视野进一步扩展到 data-centric AI，本文也与其核心思想形成对话。data-centric AI 强调，模型表现的提升并不总依赖更复杂的网络结构，也可以通过改善数据质量、标签一致性与模式覆盖度获得。当前项目是这一思想在动态金融世界中的高维延伸：它所改善的不是静态数据集，而是一个持续更新、跨来源、跨频率的市场观测世界。

3 理论框架：从潜在市场状态到 AI 可见世界

3.1 潜在市场状态与观测层

设真实但不可完全观测的市场状态为 S_t 。它不仅包括价格，还包括订单流、库存约束、宏观风险偏好、链上供给、事件冲击、衍生品拥挤度以及执行摩擦等。对任何 AI 系统而言，真正可用于判断的并不是 S_t 本身，而是若干观测算子作用后的结果：

$$X_{j,t} = h_j(S_t) + \nu_{j,t}, \quad j = 1, \dots, J, \quad (3.1)$$

其中 $h_j(\cdot)$ 为第 j 个来源的观测函数， $\nu_{j,t}$ 为数值误差、延迟误差或定义误差。

传统模型优先思路通常直接讨论如何用某个函数 $f(\cdot)$ 将若干 $X_{j,t}$ 映射到下一步预测：

$$\hat{y}_{t+1} = f(X_{1,t}, \dots, X_{J,t}). \quad (3.2)$$

但式 (3.2) 略去了一个更重要的前提：不同观测是否完整、是否可比较、是否过期，以及是否适合进入 AI 主视图。当前项目的理论意义在于，在 $f(\cdot)$ 之前增加了一层“世界模型生成函数”：

$$\mathcal{W}_t = G\left(\{X_{j,\tau}\}_{j \leq J, \tau \leq t}, Q_t, R_t, A_t\right), \quad (3.3)$$

其中 Q_t 为质量标记系统， R_t 为 AI-ready 门控， A_t 为时间对齐与聚合规则。AI 实际处理的对象不是未经治理的原始数据，而是 $\mathcal{W}_t$ 。

3.2 世界模型质量的三维定义

定义 3.1 (宽度). 设系统在时点 t 的关键证据带数量为 K , 若第 k 条证据带达到 AI 可用门槛, 则记 $a_{k,t} = 1$, 否则为 0。则宽度指标定义为:

$$B_t = \frac{1}{K} \sum_{k=1}^K a_{k,t}. \quad (3.4)$$

定义 3.2 (稳定性). 令 $d_{j,t}$ 表示第 j 个来源的 *freshness penalty* 或时效性惩罚项, 则稳定性可写为:

$$U_t = \exp \left(- \sum_{j=1}^J \omega_j d_{j,t} \right), \quad (3.5)$$

其中 ω_j 为来源重要性权重。

定义 3.3 (诚实性). 设 $m_{j,t} = 1$ 表示第 j 路来源在质量或语义上不应进入 AI 主视图却被错误注入, 则诚实性定义为:

$$H_t = 1 - \frac{\sum_{j=1}^J m_{j,t}}{J}. \quad (3.6)$$

由此, 世界模型质量指数定义为:

$$\text{WMI}_t = B_t \times U_t \times H_t. \quad (3.7)$$

式 (3.7) 并非当前仓库中的现成字段, 而是基于项目设计抽象出的研究指标。

3.3 观测对象并非“更多特征”, 而是“值 + 时间 + 质量 + 角色”

对 AI 而言, 一个有用的市场观测对象不应只是数值 $x_{j,t}$, 还应包括时间、质量、可用性和角色元数据:

$$O_{j,t} = (x_{j,t}, \tau_{j,t}, q_{j,t}, g_{j,t}, r_{j,t}). \quad (3.8)$$

其中 $\tau_{j,t}$ 为最新可用时间, $q_{j,t}$ 为质量状态, $g_{j,t}$ 为是否进入主视图的门控状态, $r_{j,t}$ 为该对象在世界模型中的语义角色。于是, AI 真正消费的是带认识论语义的状态对象集合, 而非平面特征矩阵。

3.4 异步观测状态空间与时滞误差

加密市场数据天然具有异步观测特征。设潜在状态演化满足:

$$S_{t+1} = F(S_t, \eta_{t+1}), \quad (3.9)$$

其中 η_{t+1} 为状态扰动。第 j 个来源在时点 t 被系统看到的并非同步状态 S_t ，而是带滞后的观测：

$$X_{j,t}^{obs} = h_j(S_{t-\ell_{j,t}}) + \nu_{j,t}, \quad (3.10)$$

其中 $\ell_{j,t} \geq 0$ 为来源级时滞。若 $h_j(\cdot)$ 满足 Lipschitz 条件，则有：

$$\|h_j(S_t) - h_j(S_{t-\ell_{j,t}})\| \leq L_j \sum_{u=t-\ell_{j,t}+1}^t \|S_u - S_{u-1}\|. \quad (3.11)$$

因此，即便数值采集完全正确，只要时滞存在，AI 看到的也可能是“过去的世界”。

令 $\tilde{S}_t$ 表示由项目生成的世界模型所恢复的可观测状态，则可将世界模型重建误差抽象写为：

$$\|\tilde{S}_t - S_t\| \leq C_1 \sum_{j=1}^J \omega_j \ell_{j,t} + C_2 \sum_{j=1}^J \omega_j \|\nu_{j,t}\| + C_3 \sum_{j=1}^J \omega_j (1 - z_{j,t}), \quad (3.12)$$

其中三项分别对应时滞误差、观测噪声与缺失/门控信息损失。项目中的 `latest_*` 机制、`freshness/TTL` 规则和 `is_ready_for_ai` 门控，正分别针对这些项进行控制。

左侧展示仅含价格、成交量、基础技术指标和少量新闻的薄世界模型；右侧展示加入执行层、衍生品、宏观、链上、供给侧、期权、替代数据及质量元数据的厚世界模型；底部连接至 AI 分析质量、解释连续性、置信校准与可审计性。

图 1 薄世界模型与厚世界模型的理论对照框架




图 2 异步观测、时滞误差与世界编译算子示意图

3.5 信息滤子与世界编译算子

从概率论角度，可以把项目看作在构造从“原始信息滤子”到“AI 可见滤子”的映射。定义：

$$\mathcal{F}_t^{raw} = \sigma\left(\{X_{j,\tau}^{obs}\}_{j \leq J, \tau \leq t}\right), \quad (3.13)$$

表示系统在时点 t 之前理论上可接触到的全部原始信息；再定义：

$$\mathcal{F}_t^{AI} = \sigma(\mathcal{W}_t^{AI}, \mathcal{D}_t), \quad (3.14)$$

表示最终供 AI 使用的主视图与诊断视图共同张成的信息集。当前项目的关键贡献，不只是扩大 $\mathcal{F}_t^{raw}$ ，而是定义了从 $\mathcal{F}_t^{raw}$ 到 $\mathcal{F}_t^{AI}$ 的编译算子：

$$\Pi_t = \mathcal{B}_t \circ \mathcal{M}_t \circ \mathcal{A}_t, \quad (3.15)$$

其中 $\mathcal{A}_t$ 表示时序对齐与快照同步， $\mathcal{M}_t$ 表示质量门控与可用性筛选， $\mathcal{B}_t$ 表示 bundle 聚合与语义重组。于是：

$$\mathcal{W}_t^{AI} = \Pi_t(\mathcal{F}_t^{raw}). \quad (3.16)$$

3.6 世界模型质量与 AI 置信校准

设 AI 在时点 t 针对某个市场机制或 regime 输出后验分布 $p(r_t | \mathcal{W}_t)$ ，并给出显式置信度 conf_t 。若 WMI_t 很低而 conf_t 却维持很高，则该系统本质上是在“高不确定世界中假装确定”。为刻画这一风险，定义示意性校准惩罚：

$$\text{ECP}_t = \mathbf{1}\{\text{conf}_t > \bar{c}\} \mathbf{1}\{\text{WMI}_t < \underline{w}\}. \quad (3.17)$$

当前项目通过 `quality_flag`、`is_ready_for_ai`、`risk_flags` 与 `evidence` 等对象，为下游 AI 实现有边界的置信表达提供了底层语义。

3.7 信息论视角：证据带的边际信息价值

从信息论角度，项目的作用可理解为降低 AI 对潜在市场状态或机制标签的不确定性。设 R_t 为 AI 所关心的市场机制标签，则薄世界模型与厚世界模型之间的差异可写为：

$$H(R_t | \mathcal{I}_t^{thin}) - H(R_t | \mathcal{I}_t^{thick}) = I(R_t; \mathcal{I}_t^{thick} \setminus \mathcal{I}_t^{thin} | \mathcal{I}_t^{thin}). \quad (3.18)$$

进一步地，可将第 k 条证据带在任务 m 下的边际信息贡献定义为：

$$\text{MIG}_{k,t}^{(m)} = I(R_t^{(m)}; E_{k,t} | \mathcal{I}_t^{(-k)}). \quad (3.19)$$

这意味着，世界模型“更厚”不应被理解为所有新增数据等价有用，而应被理解为不同证据带对不同任务存在异质的信息增益。

3.8 因果图视角：世界模型效应为何不能被误当作普通特征扩展

设 $\mathcal{W}_t$ 为世界模型质量， A_t 为 AI 分析质量， M_t 为真实市场复杂度， O_t 为系统可观测的来源可用性冲击， C_t 为研究者未充分观测到的环境配置，则一个概念性 DAG 可写为：

$$O_t \rightarrow \mathcal{W}_t \rightarrow A_t, \quad M_t \rightarrow \mathcal{W}_t, \quad M_t \rightarrow A_t, \quad C_t \rightarrow \mathcal{W}_t, A_t. \quad (3.20)$$

式 (3.20) 表明：若不对 M_t 和 C_t 进行控制，仅观察“世界模型更厚时 AI 表现更好”，并不能直接推出因果结论。当前项目的重要优势之一，在于它保留了来源级状态、质量标记和运行日志，使研究者更可能围绕 O_t 这类接近外生的观测可得性冲击开展识别。

以 DAG 形式展示真实市场复杂度、来源可用性冲击、系统配置、世界模型质量与 AI 分析质量之间的路径关系，并标示潜在后门路径与可识别路径。

图 3 世界模型效应的因果图与选择偏差路径

3.9 拒绝判断的贝叶斯决策规则

若承认世界模型质量本身是波动的，则成熟的 AI 分析系统不仅要学会“判断”，还要学会“何时不该判断”。设动作集合为：

$$\mathcal{A} = \{\text{bullish}, \text{bearish}, \text{neutral}, \text{abstain}\}, \quad (3.21)$$

损失函数为 $\ell(a, R_t)$ ，拒绝判断成本为 c_{abs} ，则最优动作满足：

$$a_t^* = \arg \min_{a \in \mathcal{A}} \mathbb{E}[\ell(a, R_t) \mid \mathcal{W}_t]. \quad (3.22)$$

当

$$\min_{a \neq \text{abstain}} \mathbb{E}[\ell(a, R_t) \mid \mathcal{W}_t] > c_{abs}, \quad (3.23)$$

最优动作即为 abstain。项目中的质量暴露对象使这种规则具备可实现的状态条件。

3.10 世界模型改善的是解释空间，而不仅是预测空间

对承担市场分析任务的 AI 而言，更关键的对象往往不是单步数值预测，而是解释空间本身。设 Φ_t 表示时点 t 上 AI 可生成的机制解释集合，则薄世界模型和厚世界模型的差异不仅体现在点预测误差上，也体现在：

$$\Phi_t^{thin} \neq \Phi_t^{thick}, \quad (3.24)$$

以及

$$\Pr(\phi_t^* \in \Phi_t^{thick}) > \Pr(\phi_t^* \in \Phi_t^{thin}), \quad (3.25)$$

其中 ϕ_t^* 表示更符合真实市场状态的机制解释。换言之，当前项目的价值之一，不是提高 AI 的“答案速度”，而是扩大其“正确问题空间”。

4 当前项目如何生成 AI 市场世界模型

4.1 总体分层：从真实世界到 AI 上下文

项目文档在顶层给出如下链路：

真实世界 → 数据层采集与标准化 → 数据库与 latest_* 快照 → 逻辑层重组
→ AI 分析 → 交易决策/执行

这一链路表明，项目不直接负责最终交易，而是负责把真实世界压缩为 AI 可消费世

界。因此，该项目在 AI 交易栈中的位置更接近“市场现实的操作系统层”而非“策略层”。

建议正式绘制为横向流程图：真实市场事件、价格、链上、宏观与新闻输入，经由 data layer 标准化和历史落库、`latest_*` 快照、质量门控与 logic layer 聚合后，形成 AI-ready bundle。

图 4 从真实世界到 AI 世界对象的状态编译链

4.2 模块化观测系统

从项目主入口可识别出 8 个自动启动常驻数据模块与 3 个逻辑聚合模块。表 1 汇总了这些模块在世界模型中的角色。

表 1 项目的世界模型模块映射

层级	模块	在世界模型中的角色
交易所观测层	exchange_data	提供现货、ticker、orderbook、funding、trade flow、open interest、liquidations、positioning、basis 等对象
宏观观测层	macro_data	提供 DXY、利率、股指、VIX、信用利差、商品等跨资产背景
新闻/事件层	news_data, event_calendar_data	提供近期叙事、监管与未来催化剂结构
链上层	onchain_data	提供资本流、储备、桥流、TVL、网络使用与质押状态
供给层	tokenomics_data	提供解锁、流通盘、国库钱包流、质押率等供给侧状态
期权层	options_data	提供隐含波动率、墙位、Gamma、期权流量与到期结构
替代层	alternative_data	提供注意力、开发者活跃度、稳定币脉冲等慢变量
技术与聚合层	technical_indicators, exchange_comparison, ai_market_context	将多层观测转化为 AI-ready 的结构化状态对象

注：表中模块分类依据来自项目主调度入口与文档中的证据带定义。表格采用三线表格式，以便直接用于投稿排版。

4.3 latest_* 快照：从历史仓库到在线世界

项目反复强调大量使用 latest_* 表，这是其核心架构特征。数据库中存在的快照表包括 latest_tickers、latest_funding_rates、latest_orderbook_snapshots、latest_macro_timeseries、latest_onchain_timeseries、latest_tokenomics_timeseries、latest_options_timeseries、latest_alternative_timeseries 等。

这一设计对应两层不同的数据哲学：历史层用于可追溯性、回算和研究；当前上下文层用于让 AI 在低延迟条件下读取“现在市场是什么样”。从统计角度看，这相当于把历史路径信息与时点状态信息解耦，从而降低版本不一致和时间错配风险。

4.4 质量治理：从“采到”到“可供 AI 使用”

项目至少区分三层质量语义：health_status 用于判断来源是否健康运行；quality_flag 用于判断 latest 样本是 ok、partial、fallback、stale 还是 unknown；is_ready_for_ai

用于判断某一路来源是否可以直接进入 AI 主视图。可定义：

$$z_{j,t} = \begin{cases} 1, & \text{若来源 } j \text{ 在时点 } t \text{ 达到 AI-ready 门槛,} \\ 0, & \text{否则.} \end{cases} \quad (4.1)$$

于是，AI 主视图真正看到的是：

$$\mathcal{W}_t^{AI} = \{X_{j,t} : z_{j,t} = 1\}, \quad (4.2)$$

而不是所有已落库对象的并集。

4.5 AI 主视图与原始诊断视图分离

项目在 bundle 中同时保留 AI 直接消费字段、raw_* 字段、ai_excluded_sources、source_health 与 quality_notes。这一设计避免了“完整性幻觉”：真实存在的数据全部被保留，但哪些适合 AI 直接信任、哪些只能作为诊断证据，必须显式分层。该设计是诚实性在工程层面的具体实现。

4.6 bundle：世界模型的对象化表达

ai_market_context bundle 将世界对象组装为统一结构，至少包括：

- market_microstructure
- derivatives_structure
- cross_exchange_execution
- onchain_capital_flow
- tokenomics_supply_pressure
- macro_regime
- news_and_events
- attention_and_builder_activity

同时，系统基于八证据带生成 coverage_score、data_quality_flag、risk_flags 与 evidence。因此 bundle 不是静态 JSON，而是带有认识状态的对象。




图 5 AI bundle 的八证据带覆盖与质量暴露结构

4.7 模块、失真风险与校正机制的对应关系

若将项目视为一个世界模型生成器，则每个模块的价值并不只是“多采一类数据”，而是“校正某类系统性失真”。表 2 总结了这种映射。

表 2 模块层与世界模型失真校正机制

模块/证据带	主要校正的市场失真	对 AI 的直接意义
<code>exchange_data</code>	仅看收盘价而忽略执行摩擦、盘口深度与拥挤方向	让 AI 区分价格变化与可执行市场结构
<code>macro_data</code>	将加密波动误读为纯内部叙事，忽略全球风险偏好冲击	让 AI 识别外生流动性环境与风险偏好切换
<code>news_data</code> + <code>event_calendar_data</code>	只看已发生价格而忽略叙事驱动与未来催化剂	让 AI 识别信息冲击的前后顺序与事件窗口
<code>onchain_data</code>	只看交易所内价格而忽略链上资本迁移与储备变化	让 AI 识别资本流、桥流、TVL 与储备压力
<code>tokenomics_data</code>	忽略解锁、供给释放和国库钱包转移的卖压	让 AI 识别供给侧冲击而非只看需求侧价格
<code>options_data</code>	忽略隐含波动率、墙位、Gamma 与到期结构约束	让 AI 识别凸性供需和衍生品主导状态
<code>alternative_data</code>	忽略注意力、开发者活跃度与稳定币脉冲等慢变量	让 AI 识别叙事热度与基础设施活跃度
<code>technical_indicators</code>	原始观测分散，难对齐，难直接供 AI 使用	把多源观测压缩为统一 AI-ready 世界对象

注：表中“主要校正的市场失真”列是该表的理论核心，建议在正式排版中以斜体或更窄列宽突出显示。

4.8 数据库表族与认识论分层

若从数据库本体观察当前项目，可以将其表结构理解为四类不同认识论对象。表 3 汇总了这一分层。

表 3 数据库表族与世界模型分层

表族	代表对象	主要功能	在世界模型中的角色
catalog 表	macro_factor_catalog, options_factor_catalog 等	定义因子身份、实体范围、来源语义	决定“世界里有哪些对象值得被命名”
history 表	tickers, macro_timeseries, onchain_timeseries 等	保留完整历史路径与可追溯样本	决定“世界如何被长期记忆”
latest 表	latest_tickers, latest_macro_timeseries 等	维护当前可读快照	决定“世界现在是什么样”
context/snapshot 表	exchange_comparison_snapshots, macro_context_snapshots, ai_market_context_snapshots	进行聚合、重写与 AI-ready 压缩	决定“世界如何被解释性呈现给 AI”

注：该表的分类依据是数据库对象的语义角色而非物理存储结构，因此更适合作为论文中的本体层说明。

4.9 版本化语义、概念漂移与诚实性契约

长期数据系统的难点不在于第一次把世界编译出来，而在于在来源变化、定义变化和市场结构变化后仍维持语义稳定。设第 v 个版本的世界编译规则为 $\Pi_t^{(v)}$ ，则不同时间上 AI 所消费的对象可能满足：

$$\mathcal{W}_t^{(v)} = \Pi_t^{(v)}(\mathcal{F}_t^{raw}), \quad \mathcal{W}_{t'}^{(v')} = \Pi_{t'}^{(v')}(\mathcal{F}_{t'}^{raw}). \quad (4.3)$$

若研究者忽略 $v \neq v'$ 所代表的规则差异，则会将“市场变了”与“世界的编译方式变了”混为一谈。与此同时，若每个观测对象都附带来源证明元数据 $\rho_{j,t}$ ，则完整对象可写为：

$$\tilde{O}_{j,t} = (x_{j,t}, \tau_{j,t}, q_{j,t}, g_{j,t}, r_{j,t}, \rho_{j,t}), \quad (4.4)$$

其中 $\rho_{j,t}$ 至少回答：数据来自哪里、何时抓取、进入 AI 主视图前经历了哪些变换。这一约束构成了世界模型的“诚实性契约”。

沿时间轴展示 bundle 规则版本切换、来源增删、质量阈值变化与概念漂移事件，并标记回看偏差可能出现的位置。

图 6 世界模型版本化、概念漂移与回看偏差控制框架

5 这个项目对 AI 分析市场的作用

5.1 扩大 AI 的可观测市场现实

若一个 AI 系统只看到价格、成交量和少量新闻，它看到的只是市场表面的投影。当前项目通过多源结构化采集，使 AI 同时看到价格、执行、拥挤、供给、风险偏好与叙事，从而把 AI 从“价格模式识别器”提升为“市场状态解释器”。

5.2 降低观测稀疏导致的伪结论

在薄输入条件下，一段价格上升既可能代表趋势延续，也可能代表 short squeeze、期权墙位附近的被动推进，或仅仅是流动性极差环境下的短暂拉升。当前项目通过把资金费率、爆仓、未平仓量、Gamma、盘口深度和跨所离散度等对象纳入世界模型，压缩了“多种机制被误读为单一信号”的概率。

5.3 把“当前世界”做成低延迟可读对象

很多数据仓库适合做离线研究，却不适合做在线 AI 读取，因为它们只关心历史落库，不关心状态对象。当前项目通过 latest_* 与 bundle 机制，把“当前世界是什么样”做成数据库层和逻辑层的一等公民，从而降低 AI 读取复杂度和状态重算成本。

5.4 让 AI 看到自己的证据边界

系统不只是提供 state，还提供 state of observability。通过 quality_flag、is_ready_for_ai、ai_excluded_sources 与 risk_flags，项目使下游 AI 能够看到“自己看到世界的质

量”，而不是错误地把所有输入等价对待。

5.5 支持竞争性解释、拒绝判断与尾部风险前验诊断

当前项目使 AI 在面对同一价格路径时，能够比较多种竞争性机制解释，而不是被迫选择单一路径叙事。进一步地，项目中的质量暴露对象为拒绝判断规则提供了条件状态；同时，funding 扭曲、basis 异常、爆仓堆积、跨所离散度、期权墙位、链上大额转账与供给解锁等对象，还使 AI 能够把尾部风险识别从价格后验反应前移到状态前验诊断。

5.6 提高 AI 输出的可审计性与机构可用性

在真实机构环境中，不可审计的 AI 结论很难进入研究、风控和执行流程。项目通过保留主视图和诊断视图、保留 evidence 与 risk_flags、保留历史层与 latest 层之间的映射关系，为 AI 结论的追溯、复核和审计提供了基础条件。

5.7 建立跨模型、跨团队、跨阶段分析的共同语言

机构内部真正的复杂性往往来自多人、多模型、多阶段协作。当前项目通过 bundle 与 context/snapshot 表建立了共享的市场语义层，使不同团队讨论的更接近“我们是否同意当前的市场状态和证据边界”，而非“我们是否使用了不同口径的数据口袋”。

6 如何实证评估“厚世界模型”的价值

6.1 基本研究设计

围绕厚世界模型相对于薄世界模型的增量价值，定义两类信息集：

$$\mathcal{I}_t^{thin} = \{\text{price, volume, basic indicators, simple news}\}, \quad (6.1)$$

$$\mathcal{I}_t^{thick} = \{\mathcal{I}_t^{thin}, \text{microstructure, derivatives, macro, on-chain, tokenomics, options, alternative, quality me}\} \quad (6.2)$$

在相同预测器类 $\mathcal{F}$ 下，比较

$$\hat{y}_{t+1}^{thin} = f(\mathcal{I}_t^{thin}), \quad \hat{y}_{t+1}^{thick} = f(\mathcal{I}_t^{thick}). \quad (6.3)$$

但本文强调，评价对象不应只限于收益预测损失，还应包括 regime 分类稳定性、解释连续性、证据归因率、无支撑断言率与陈旧输入敏感度。

6.2 面向世界模型质量的回归框架

设 $Q_{i,t+h}$ 表示资产 i 在时点 t 上由固定 AI 分析器产生的分析质量指标，则可估计：

$$Q_{i,t+h} = \alpha_i + \lambda_t + \beta_1 \text{WMI}_{i,t} + \beta_2 B_{i,t} + \beta_3 U_{i,t} + \beta_4 H_{i,t} + \Gamma^\top Z_{i,t} + \varepsilon_{i,t+h}, \quad (6.4)$$

其中 α_i 为资产固定效应， λ_t 为时间固定效应， $Z_{i,t}$ 为控制变量。

若要比较厚世界模型在高压市场中的边际作用，可进一步定义：

$$\Delta Q_{i,t+h} = Q_{i,t+h}^{thick} - Q_{i,t+h}^{thin}, \quad (6.5)$$

并估计：

$$\Delta Q_{i,t+h} = \alpha_i + \lambda_t + \theta_1 \text{WMI}_{i,t} + \theta_2 \text{Stress}_t + \theta_3 \text{WMI}_{i,t} \times \text{Stress}_t + u_{i,t+h}. \quad (6.6)$$

左侧为 B_t 、 U_t 、 H_t 及 WMI_t 的构成，中部为固定 AI 分析器与控制变量集合 $Z_{i,t}$ ，右侧为 $Q_{i,t+h}$ 、EAR、UCR、EV 等结果变量，并标出高压市场状态交互路径。

图 7 世界模型质量指数与 AI 分析质量的计量识别框架

6.3 事件研究：模块中断与来源降级

当前项目的一个独特优势在于，其运行日志、质量标记与来源级状态使研究者可围绕“世界模型受损事件”开展准实验研究。若某关键来源在事件时点 T_0 附近发生中断、严重陈旧或被 `is_ready_for_ai` 剔除，则可估计：

$$Q_{i,\tau} = \alpha_i + \lambda_\tau + \sum_{k \neq -1} \delta_k D_{i,\tau}^{(k)} + \epsilon_{i,\tau}, \quad (6.7)$$

其中 $D_{i,\tau}^{(k)}$ 为相对事件时点的 lead/lag 指示变量。




图 8 模块中断与来源降级的事件研究设计图

6.4 解释质量的统计评价体系

若研究对象是 AI 的市场分析能力，而非单纯数值预测，则需要专门的解释质量指标。定义证据归因率（EAR）：

$$\text{EAR}_t = \frac{\#\{\text{被明确绑定到 bundle/evidence 的判断}\}}{\#\{\text{总判断}\}}, \quad (6.8)$$

无支撑断言率（UCR）为：

$$\text{UCR}_t = 1 - \text{EAR}_t, \quad (6.9)$$

解释波动率（EV）可定义为：

$$\text{EV}_t = \frac{d(\phi_t, \phi_{t-1})}{1 + d(\mathcal{W}_t, \mathcal{W}_{t-1})}, \quad (6.10)$$

其中 $d(\cdot, \cdot)$ 为某种距离度量。

6.5 多目标评价与 Pareto 前沿

若继续沿用单一预测损失作为世界模型优劣的判断标准，则容易低估项目最关键的制度价值。更合理的做法是把世界模型评估视为多目标优化问题，定义：

$$\mathbf{J}_t = (\text{Predictive Accuracy}, \text{Explanation Stability}, \text{Calibration}, \text{Auditability}). \quad (6.11)$$

厚世界模型的优势未必总体现为单一维度最优，但可能体现为更优的 Pareto 前沿，即在不显著牺牲预测表现的同时，大幅提升解释稳定性、置信校准与可审计性。

表 4 世界模型评估指标的多目标体系

维度	代表指标	统计含义	与当前项目的对应对象
预测维度	方向损失、分位数损失、尾部事件识别率	世界模型是否提升数值判断	多源输入、技术指标、上下文聚合
解释维度	EV、机制标签稳定性、竞争性解释覆盖率	世界模型是否提升解释连续性	bundle、evidence、risk_flags
校准维度	ECP、置信偏差、stale sensitivity	世界模型是否支持有边界的置信表达	quality_flag、is_ready_for_ai
审计维度	EAR、UCR、来源溯源完整率	世界模型是否支持追溯与复核	raw/diagnostic 视图、历史表、latest 表

注：表中部分指标并非当前仓库中的既成字段，而是基于现有设计可直接构造的研究对象。正式投稿时建议与附录中的构造公式配套使用。

6.6 蒙特卡洛与代理市场仿真

由于真实市场中的来源中断和极端状态未必足够频繁，未来研究还可以引入蒙特卡洛或代理市场仿真。令潜在状态满足：

$$S_t = (S_t^{liq}, S_t^{crowd}, S_t^{macro}, S_t^{supply}, S_t^{narrative}), \quad (6.12)$$

并对不同来源的人为设置时滞、噪声、缺失率和门控规则。这样可分离现实数据中难以单独识别的几个维度：状态复杂度、来源异步性、门控强度与 AI 分析器本身的鲁棒性。

6.7 发表级识别要求

若要把本文真正推进为期刊级实证论文，至少需要满足以下要求：

1. 对所有世界模型指标给出可重复构造的代码与冻结样本；
2. 将 bundle 构造逻辑版本化，避免后续系统迭代引起回看偏差；
3. 对不同市场阶段分别报告结果，避免把平稳阶段平均改善错误外推到压力阶段；
4. 将来源中断、数据陈旧、质量降级与市场本身的剧烈波动做清晰区分；
5. 在任何涉及收益或方向预测的扩展研究中，严格区分“改善了 AI 的世界理解”与“改善了可交易经济价值”。

7 与经典文献的对话

7.1 与 Fama–French、Cochrane 和机器学习资产定价的关系

Fama–French 框架擅长用少量低频因子总结风险补偿结构，而 Cochrane 的贴现率框架强调条件信息集的变化 [5, 3]。若说 Fama–French 研究的是“给定世界之后哪些因子解释收益”，那么本文与当前项目所研究的是“AI 所看到的世界应如何被构造，才能让这些因子解释有意义”。

相对于机器学习资产定价文献，本文并不把边际贡献理解为“再加入一组特征”或“换一个更强模型”，而是把其理解为“如何治理一个高维、异步、跨制度来源的信息世界”。因此，当前项目更接近 market ontology engineering，而不仅是 feature engineering。

7.2 与测量误差、鲁棒控制和统计学习理论的进一步对话

测量误差文献关注观测变量受噪声污染后对估计和预测的影响 [7, 2]；鲁棒控制文献关注决策者在不确定模型下的保守最优化 [9]；统计学习理论与表示学习文献关注表示质量与下游任务性能的关系。本文的边际位置在于：将这些思想推进到多源、异步、分层和门控环境中，研究“一个市场世界被多种不同方式不完整地观测时，如何仍然为 AI 构造可靠的信息表面”。

7.3 与 data-centric AI 的关系

data-centric AI 强调通过改善数据质量、标签一致性和覆盖度提升模型表现。本文则表明，在金融市场中，真正需要被治理的不是静态数据集，而是一个持续变化的观测世界。项目中的 latest_*, quality_flag、is_ready_for_ai、bundle 和版本治理，正是 data-centric AI 在动态金融环境中的制度化延伸。

8 局限性、内生性与外部有效性

8.1 内生性与识别风险

即使未来围绕该世界模型开展实证评估，也会面临若干内生性问题：来源选择内生性、反向因果、异步采样偏差以及部署状态依赖。尤其是在高波动阶段，世界模型更“厚”与市场更“异常”可能同时发生，因此必须严肃处理式 (3.20) 所揭示的后门路径。

8.2 规范性命题与实证命题的区分

本文应被理解为一篇理论与架构研究论文，而不是一篇已经完成发表级样本构造的策略论文。它对于第一类命题——“面向 AI 的市场数据系统应具备什么性质”——给出了强规范性案例；但对于第二类命题——“这些设计究竟在多大程度上改善了 AI 判断能力”——仍需未来实证工作回答。

8.3 外部有效性与模型-世界交互偏差

加密市场具有 24/7 交易、跨交易所分裂、链上透明但解释噪声大、代币供给制度多样等特征，这使本文的理论和项目设计在该场景中特别自然。若将其平移 to 股票、债券或商品市场，则证据带重要性、时间结构与质量门槛都可能不同。

此外，还存在一个更细的风险：即便世界模型质量较高，AI 分析器也可能系统性误读某些世界对象，从而形成“二阶误差”。换言之，世界模型质量的提升并不能替代对下游 AI 行为的独立审查。

9 结论

本文围绕一个被多数 AI 交易叙事忽略的问题展开：在真实金融市场中，AI 失败往往首先不是模型层失败，而是世界模型层失败。当前项目的独特价值，不在于它已经证明某个策略必然赚钱，而在于它把“面向 AI 的市场世界模型”从一个口号推进为一套可实现、可审计、可扩展的分层系统。

综合项目文档与代码结构，可以得出如下结论。第一，当前系统已经形成一个覆盖微观结构、衍生品拥挤、宏观背景、链上资本流、供给压力、期权结构、新闻事件与替代数据的高维观测体系。第二，项目通过 `latest_*` 快照、质量门控、主视图与诊断视图分离、`bundle` 聚合和调度矩阵，把“当前市场世界”编译为 AI 可直接消费的状态对象。第三，项目对 AI 市场分析的最大贡献并不是告诉 AI 明天会涨还是会跌，而是先让 AI 看到一个更接近真实市场、并且知道自己看到世界质量边界的市场现实。

因此，若用一句话概括本文的研究结论，那就是：**对于长期可用的 AI 市场分析系统而言，最昂贵、最难复制、最容易形成壁垒的，不是 prompt，也不是单一模型，而是稳定的数据世界模型。**

A 核心符号表

符号	含义
S_t	潜在真实市场状态
$X_{j,t}$	第 j 个来源对市场状态的观测值
$X_{j,t}^{obs}$	带时滞和噪声的实际可观测值
$\ell_{j,t}$	来源级时滞
$\nu_{j,t}$	观测噪声或定义误差
$\mathcal{W}_t$	项目生成的世界模型对象
$\mathcal{W}_t^{AI}$	进入 AI 主视图的世界对象
$\mathcal{D}_t$	诊断与审计辅助对象集合
B_t	世界模型宽度指标
U_t	世界模型稳定性指标
H_t	世界模型诚实性指标
WMI_t	世界模型质量指数
Π_t	从原始信息滤子到 AI 可见信息滤子的编译算子
Φ_t	AI 可生成的机制解释集合
$Q_{i,t+h}$	面向 AI 分析任务的质量指标
EAR_t	证据归因率
UCR_t	无支撑断言率
EV_t	解释波动率
ECP_t	置信校准惩罚
$MIG_{k,t}^{(m)}$	第 k 条证据带在任务 m 下的边际信息增益

B 项目代码事实摘要

基于项目文档与代码结构，当前系统至少具有如下可验证事实：

1. 自动启动常驻数据模块 8 个，逻辑聚合模块 3 个；
2. SQLite 应用表 42 张；
3. 技术指标输出列 181 个，市场上下文增强列 21 个，跨所执行状态列 90 个；
4. 宏观因子 15 个、链上因子 17 个、tokenomics 因子 12 个、期权因子 55 个、替代因子 28 个；
5. 默认交易对包括 BTC/USDT、ETH/USDT、SOL/USDT、SUI/USDT；
6. 默认交易所包括 binance、okx、bybit；
7. 默认 K 线周期包括 1m、5m、15m、1h、4h、1d。

C 面向发表级研究的经验研究协议

C.1 最小实验单元

一个最小实验单元可定义为：一个资产或交易对、一个时间窗口、一个固定 AI 分析器、一种信息世界配置和一组统一评估指标。

C.2 推荐比较组

1. 薄世界模型：价格、成交量、基础技术指标；
2. 中等世界模型：在薄世界模型上加入微观结构和衍生品拥挤；
3. 厚世界模型：加入宏观、链上、tokenomics、期权、替代数据；
4. 厚世界模型加门控：进一步启用 `quality_flag` 和 `is_ready_for_ai`。

C.3 最低报告标准

1. 报告所有信息集配置下的样本内与样本外区分；
2. 报告模块不可用或质量降级时的鲁棒性结果；
3. 报告不同市场压力阶段的异质性结果；
4. 报告世界模型版本号与 bundle 构造规则版本号；
5. 明确区分“提升了分析质量”和“提升了可交易经济价值”。

参考文献

- [1] Asness C S, Moskowitz T J, Pedersen L H. Value and Momentum Everywhere[J]. Journal of Finance, 2013, 68(3): 929–985.
- [2] Carroll R J, Ruppert D, Stefanski L A, Crainiceanu C M. Measurement Error in Nonlinear Models: A Modern Perspective[M]. 2nd ed. Boca Raton: Chapman and Hall/CRC, 2006.
- [3] Cochrane J H. Asset Pricing[M]. Revised Edition. Princeton: Princeton University Press, 2005.

- [4] Fama E F, French K R. The Cross-Section of Expected Stock Returns[J]. Journal of Finance, 1992, 47(2): 427–465.
- [5] Fama E F, French K R. Common Risk Factors in the Returns on Stocks and Bonds[J]. Journal of Financial Economics, 1993, 33(1): 3–56.
- [6] Fama E F, French K R. A Five-Factor Asset Pricing Model[J]. Journal of Financial Economics, 2015, 116(1): 1–22.
- [7] Fuller W A. Measurement Error Models[M]. New York: Wiley, 1987.
- [8] Gu S, Kelly B, Xiu D. Empirical Asset Pricing via Machine Learning[J]. Review of Financial Studies, 2020, 33(5): 2223–2273.
- [9] Hansen L P, Sargent T J. Robustness[M]. Princeton: Princeton University Press, 2008.
- [10] Harvey C R, Liu Y, Zhu H. ...and the Cross-Section of Expected Returns[J]. Review of Financial Studies, 2016, 29(1): 5–68.
- [11] Jegadeesh N, Titman S. Returns to Buying Winners and Selling Losers: Implications for Stock Market Efficiency[J]. Journal of Finance, 1993, 48(1): 65–91.
- [12] Kelly B T, Pruitt S, Su Y. Characteristics Are Covariances: A Unified Model of Risk and Return[J]. Journal of Financial Economics, 2019, 134(3): 501–524.
- [13] Liu Y, Tsyvinski A, Wu X. Common Risk Factors in Cryptocurrency[J]. Journal of Finance, 2022, 77(2): 1133–1177.
- [14] Makarov I, Schoar A. Trading and Arbitrage in Cryptocurrency Markets[J]. Journal of Financial Economics, 2020, 135(2): 293–319.
- [15] Nagel S. Machine Learning in Asset Pricing[M]. Princeton: Princeton University Press, 2021.
- [16] Shmueli G. To Explain or to Predict?[J]. Statistical Science, 2010, 25(3): 289–310.